

Clasificación de Enfermedades en Hojas de Cultivos mediante Redes Neuronales Convolucionales y Transfer Learning



Proyecto – Entrega 1

Fundamentos de Deep Learning

Daniel Alejandro Yepes Mesa

Universidad de Antioquia
Facultad de Ingeniería
Medellín
2026

1. Contexto

Las enfermedades en plantas son un problema real que afecta directamente la producción de los agricultores. Detectarlas a tiempo hace una diferencia importante, pero hacerlo de forma manual requiere personal especializado que no siempre está disponible. En este contexto, las técnicas de visión por computador basadas en Deep Learning, centrándonos principalmente en las Redes Neuronales Convolucionales (CNNs), han demostrado un potencial interesante para automatizar la clasificación de enfermedades a partir de imágenes de hojas en múltiples estudios y trabajos académicos. En este proyecto le daremos un enfoque de Transfer Learning permitiendo reutilizar modelos pre entrenados y adaptarlos a problemas específicos con relativamente pocos datos, pues contamos con este aprendizaje previo, reduciendo significativamente los recursos y el tiempo de entrenamiento necesarios. Me parece un proyecto particularmente relevante para el contexto Colombiano.

2. Objetivo del Machine Learning

Objetivo principal: Desarrollar e implementar un sistema que pueda clasificar imágenes, identificando automáticamente la especie de el cultivo y la enfermedad presente (si existe) a partir de una fotografía de sus hojas, utilizando Redes Neuronales Convolucionales con Transfer Learning.

Proceso: Dada una imagen RGB de una hoja de cultivo debemos predecir la clase a la cual pertenece en un conjunto de 38 categorías que representan una combinación de especie y estado de la planta (sana o enferma) . Es un problema de **clasificación multiclase supervisado**.

Para abordarlo, dividí el trabajo en tres fases:

- **Fase 1 (Baseline):** CNN simple desde cero (3-4 bloques convolucionales) para establecer una línea base de desempeño.
- **Fase 2 (Transfer Learning):** Comparación sistemática de al menos tres arquitecturas preentrenadas: VGG16, ResNet50 e InceptionV3, aplicando fine-tuning.
- **Fase 3 (Interpretabilidad):** Visualización con GradCAM para identificar las regiones de la hoja que activan las predicciones del modelo.

3. Dataset

Nombre: PlantVillage Dataset (versión color, sin aumentar).

Fuente: El dataset está disponible en Kaggle, que es la plataforma desde donde se trabajó para este proyecto.

Paper original: Este dataset fue creado por Mohanty et al. (2016), quienes también publicaron los primeros resultados usando Deep Learning sobre estas imágenes.

Característica	Detalle
Total de imágenes	54,305
Número de clases	38 (combinaciones especie-enfermedad)
Especies de cultivos	14 (tomate, papa, maíz, manzana, uva, cereza, durazno, fresa, arándano, frambuesa, soya, calabaza, pimentón, naranja)
Tipos de enfermedades	26 enfermedades (17 fúngicas, 4 bacterianas, 2 virales, 2 por moho, 1 por ácaro) + 12 clases saludables
Resolución	256 × 256 píxeles (RGB, 3 canales)
Tamaño en disco	~828 MiB (descarga) / ~815 MiB (en disco)
Formato	JPEG, organizado en carpetas por clase
Balanceo de clases	Desbalanceado (de ~275 a ~5,357 imágenes por clase)

Distribución de clases: El dataset no está balanceado: algunas clases tienen más de 5,000 imágenes y otras apenas 275. Para manejar eso, planeo usar pesos por clase y data augmentation durante el entrenamiento.

Condiciones de captura: Vale la pena aclarar que las fotos fueron tomadas en laboratorio, con fondo controlado y buena iluminación. Eso hace el problema más fácil de lo que sería en campo real, algo que voy a tener en cuenta al analizar los resultados.

4. Métricas de Desempeño

Métricas de Machine Learning:

- **Accuracy global:** qué tan seguido el modelo acierta en general.
- **F1-Score (macro y por clase):** importante acá porque las clases están desbalanceadas, así que el accuracy no nos entrega todo el análisis.

- **Precisión y Recall por clase:** Necesario para ver en cuáles clases el modelo falla más.
- **Matriz de confusión normalizada:** para entender qué enfermedades pueden llegar a generar confusiones entre sí.
- **Curvas de aprendizaje:** para verificar que el modelo no está memorizando los datos de entrenamiento.

Métricas de negocio:

- **Recall por enfermedad crítica:** Minimizar falsos negativos en enfermedades de alto impacto económico (p.ej., Late Blight en tomate/papa).
- **Tiempo de inferencia:** Viabilidad de predicción en tiempo real (menor a 10s) para una potencial aplicación móvil.

5. Referencias y Resultados Previos

Para entender qué difícil podría ser este problema y qué resultados son razonables obtener, revisé algunos trabajos previos sobre este mismo dataset. El paper original de Mohanty et al. (2016), que es quienes crearon PlantVillage, reportaron un 99.35% de accuracy usando GoogLeNet con Transfer Learning. Otros trabajos como el de Too et al. (2019) llegan a resultados similares con DenseNet. En general, los modelos basados en Transfer Learning superan con bastante margen a los entrenados desde cero, lo que justifica el enfoque que voy a usar en este proyecto. También encontré un kernel en Kaggle donde aplican ResNet50 sobre este mismo dataset y obtienen resultados por encima del 95%, lo que me da una referencia práctica de qué es alcanzable con los recursos de Google Colab.

Bibliografía

- Mohanty, S. P., Hughes, D. P., & Salathé, M. (2016). Using deep learning for image-based plant disease detection. *Frontiers in Plant Science*, 7, 1419.
- Too, E. C., Yujian, L., Njuki, S., & Yingchun, L. (2019). A comparative study of fine-tuning deep learning models for plant disease identification. *Computers and Electronics in Agriculture*, 161, 272–279.
- Selvaraju, R. R. et al. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 618–626.